
ZADATAK (LR): Predikcija količine proteina u proizvodima brze hrane

U fajlu **fastfood.csv** dat je sveobuhvatan pregled nutritivnog sadržaja različitih proizvoda brze hrane iz popularnih lanaca brze hrane. Varijable dataset-a su:

- | | |
|---|---|
| • restaurant: naziv restorana | • cholesterol: holesterol |
| • item: naziv proizvoda | • sodium: natrijum |
| • calories: ukupne kalorije | • total_carb: ukupni ugljeni hidrati |
| • cal_fat: masne kalorije | • fiber: vlakna |
| • total_fat: ukupno masti | • sugar: šećer |
| • sat_fat: zasićene masti | • calcium: kalcijum |
| • trans_fat: trans-zasićene masne kiseline | • protein: protein |
-

Potrebno je uraditi sledeće:

1. Napraviti podskup podataka koji **ne** sadrži proizvode čije ukupne masti (total_fat) prelaze **125**.
2. U dataset-u dobijenom na osnovu prethodnog zahteva proveriti da li postoje nedostajuće vrednosti (NAs ili "-", " ", "") i ako je moguće, zameniti ih adekvatnim vrednostima. Prokomentarisati postupak zamene vrednosti, odnosno zašto je određen metod zamene vrednosti odabran.
3. Proceniti koje attribute je potrebno uključiti u model **linearne regresije** za predviđanje vrednosti varijable **protein**. Obavezno navesti u komentaru zašto su baš ti atributi uključeni u model. Takođe, ukoliko se neki atribut izostavi, obrazložiti zašto je izostavljen. Tako dobijeni redukovani dataset eventualno dodatno obraditi da bi bio pogodan za predviđanje vrednosti izl. varijable primenom linearne regresije.
4. Primenom linearne regresije, kreirati model za predviđanje vrednosti varijable **protein**, i na osnovu njega kreirati predviđanja.
5. Na osnovu kreiranog modela:
 - protumačiti koeficijente svake varijable, odnosno interpretirati relaciju nezavisne i zavisne varijable na osnovu vrednosti koeficijenta, **u kontekstu problema koji se rešava u zadatku**¹
 - navesti koji atributi su značajni za predikciju i na osnovu čega je to zaključeno; interpretirati taj zaključak u kontekstu problema koji se rešava u zadatku
 - objasniti šta je koeficijent determinacije (R-squared) i protumačiti njegovu vrednost, takođe **u kontekstu problema koji se rešava u zadatku**
6. Napisati šta predstavlja svaki od četiri grafikona za dijagnostiku modela linearne regresije. Objasniti šta se može uvideti na grafikonima i **protumačiti** svaki grafikon **u kontekstu problema koji se rešava u zadatku**².
7. Proveriti postojanje multikolinearnosti na urađenom modelu. Prokomentarisati rezultate provere kao i mogućnosti za poboljšanje modela.

Napomena: Varijable koje **očigledno** nema smisla koristiti za predviđanje izlazne se **mogu izbaciti bez analiziranja** (npr. Izbacivanje ID-a pri predikciji plate neke osobe) - potrebno je samo napisati komentar zasto se ta kolona izbacuje.

Svaka varijabla čiji odnos sa **izlaznom nije očigledan na prvi pogled**, mora se na neki način uporediti sa izlaznom, i na osnovu toga doneti zaključak da li se koristi u modelu li ne, sa propratnim komentarima.

¹ Značenje tog izraza je: **ne** navoditi u komentarima samo brojeke koje se dobiju, već protumačiti šta one **znače** u kontekstu problema koji se rešava u zadatku i dataset-a koji se koristi.

² Značenje tog izraza je: **ne** opisivati u komentarima samo oblik grafikona, **ne** navoditi samo kakav tj oblik **treba** da bude, već protumačiti šta tako dobijeni grafikoni i njihovi oblici **znače** u kontekstu problema koji se rešava u zadatku i dataset-a koji se koristi.